

자율주행자동차의 사고 예방을 위한 CNN 기반 블랙 아이스 검출방안 연구

A Study on the CNN(Convolution Neural Network)-based Black Ice Detection for the Prevention of Automated Vehicle Accident

강민희¹ · 이호준² · 노동준² · 송재인³ · 황기연⁴

¹홍익대학교 산업융합협동과정 스마트도시전공 박사과정 ²홍익대학교 도시공학과 학사과정

³홍익대학교 과학기술연구소 연구교수 ⁴홍익대학교 도시공학과 교수

I. 서론

1. 연구의 배경 및 목적

2016년 1월, '4차 산업혁명의 이해'를 주제로 다보스 포럼이 개최되면서 4차 산업혁명은 전 세계적으로 대두되었으며(통계청, 2017), 이는 사회적으로 큰 변화를 가져올 것으로 전망된다.

교통 분야에서는 4차 산업혁명의 일환으로 자율주행자동차가 주목받고 있으며, 이는 교통사고의 감소, 교통류 개선 등 삶의 질 향상에 기여할 것으로 평가된다(자율주행차 융·복합 미래포럼, 2018). 현재 구글, 엔비디아, 테슬라 등 국외 기업들을 중심으로 자율주행시스템의 개발 및 실험이 진행되고 있으며, 국내의 경우 「자율주행차 상용화 지원방안(2015)」, 「자율주행차 선제적 규제혁파 로드맵(2018)」을 발표하는 등 자율주행자동차 상용화 시대를 대비하고 있다. 그러나 이러한 노력에도 불구하고 자율주행 상황에서의 빈번한 교통사고와 인명피해로 인한 안전성 문제 등이 제기되어 상용화에 걸림돌이 될 것으로 예상된다.¹⁾

특히, 블랙 아이스²⁾는 겨울철 대형사고의 주원인으로 파악되며, 자율주행자동차 상용화 시대에도 심각한 상해 요인으로 예상되어 사고를 예방할 수 있는 기술이 요구되는 실정이다.

이에 본 연구는 향후 자율주행자동차의 블랙 아이스 사고 예방을 위해 인공지능 기반 중 하나인 합성곱 신경망(Convolutional Neural Network, 이하 CNN)을 기반으로 도로 내 블랙 아이스 검출방안에 대해 연구하고자 한다.

본 연구의 순서는 다음과 같다. 첫 번째로, CNN을 활용한 선행 연구를 살펴보고 이를 통해 본 연구의 차별성을 도출하고자 한다. 두 번째로, 활용 데이터의 수집 및 전처리 과정과 CNN 모델의 구조는 학습 환경 설정에서 설명한다. 마지막으로 학습 결과 분석을 토대로 결론, 연구의 한계점 및 향후 연구 과제를 제시하고자 한다.

II. 선행연구 고찰

본 장에서는 교통 분야에서 CNN을 활용한 선행연구 고찰을 수행하였으며, 이를 통해 본 연구의 차별성을 도출하고자 한다.

첫 번째로, CNN을 활용하여 도로 표면의 균열, 교통 표지판을 인식 및 분류하는 연구가 수행되고 있었으며, 이는 대부분 빠른 처리 능력을 요구하여 Mask R-CNN, Fast R-CNN을 활용하고 있음을 확인하였다(이민혜 외 2인, 2016; 양동욱 외 2인, 2017; Rongqiang Qian 외 4인, 2016). 또한, 콘크리트 균열 탐지를 위한 CNN 모델들의 성능을 비교하는 연구가 수행되고 있음을 확인하였다(설동현 외 2인, 2020).

선행연구 고찰 결과, CNN을 활용한 물체검출 연구와 CNN의 효율적인 구조를 찾는 연구가 대다수인 것으로 나타났다. 그러나 CNN을 활용한 도로 노면 상태 검출과 같은 연구에 대한 수행은 미흡하였다. 따라서 본 연구는 CNN을 활용하여 블랙 아이가 생성된 도로를 검출하는 방안을 제시하고자 한다.

III. 학습환경 설정

1. 데이터 수집 및 전처리

학습에 활용하는 데이터는 총 4개 범주(블랙 아이스(blackice), 일반 도로(road), 젖은 도로(wet road), 눈 쌓인 도로(snow road))로 분류하여 구글 이미지 검색을 통해 확보하였다. 이후, 128×128 px 크기로 크롭하여 도로의 특징을 명확하게 확인할 수 있는 데이터로 가공하였다. 다음으로 다수의 이미지 데이터를 학습하기 위해 GRAYSCALE(1 channel)로 변환하였고, 데이터 패딩(Data Padding)을 진행하였다. 데이터 패딩 유무에 따른 증강 및 학습 결과는 표 1과 같으며, 증강 과정에서 원본 데이터(Original Data)의 이미지 왜곡이 나타남을 확인하였다. 또한, 동일한 CNN 모델로 학습한 결과, 패딩 데이터(Padding Data)의 손실값(loss)이 낮으며, 정확도(accuracy)가 높게 도출되어 모든 데이터에 패딩을 진행하였다. 위 과정을 통해 GRAYSCALE 형태를 한 150×150 px 크기의 이미지 데이터 25,400장을 확보하였다.(표 2 참조)

표 1 데이터 증강 및 학습 결과

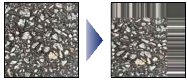
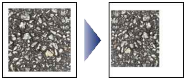
	Original Data		Padding Data	
데이터 증강 결과				
학습 결과	loss	1.39	loss	0.26
	accuracy	0.253	accuracy	0.891

표 2 데이터 개수

Class	Size	Number
blackice	150×150 px	3,900
road		4,900
wet road		4,900
snow road		3,900
Total		25,400

다음으로 데이터 셋 구축과 데이터 증강을 진행하였다. 앞선 과정을 통해 얻은 데이터를 대상으로 각 클래스당 무작위로 1,000장을 추출하여 테스트 데이터(Test Data)를 구축하였다. 이후 남은 데이터(Rest Data)를 대상으로 케라스(Keras) 라이브러리에서 제공하는 ImageDataGenerator를 사용하여 데이터를 증강시켰다. 데이터 증강 결과, 클래스별 10,000장의 데이터를 확보하였으며, 8:2 비율로 훈련 데이터(Train Data)와 검증 데이터(Validation Data)로 분류하였다. 이를 통해 구축한 최종 데이터 셋은 아래 그림 1과 같다.




그림 1 데이터 셋 구축

1) <http://www.hani.co.kr/arti/economy/it/838665.html>

2) 비·눈이 먼지 등 오염 물질과 결합해 도로에 형성된 얼음 막. 차량 제동거리가 일반 도로의 14배, 눈길의 6배 수준으로 대형사고로 이어질 가능성이 큼(<https://www.bbc.com/korean/news-50889866>).

2. CNN 모델 설계 및 학습

본 연구에 사용한 CNN 모델의 구조는 그림 3과 같이 특징 추출 영역(Feature Extraction)과 클래스 분류 영역(Classification)으로 구성된다. 특징 추출 영역에서는 합성곱 층(Convolutional layer), 맥스풀링 층(Max-pooling layer), 드롭아웃 층(Dropout layer)을 배치하였고, 활성화 함수(activation function)는 ReLU를 사용하였다. 클래스 분류 영역에서는 Fully-connected layer와 드롭아웃 층을 번갈아 배치하였으며 출력층에는 Softmax를 적용하였다.(그림 2 참조)

모델의 학습은 200 epoch, 32 batch size를 적용하였고, SGD (Stochastic Gradient Descent) Optimizer를 사용하였으며, 과적합 방지를 위해 early stopping과 0.2의 dropout rate을 설정하였다.




그림 2 CNN 모델 구조

IV. 학습 결과 및 분석

학습 결과, 표 3과 같이 Train Data와 Test Data의 loss는 0.008, 0.097로 확인되었으며, accuracy는 각각 0.998, 0.982로 확인되었다.

표 3 학습 결과

Class	loss	accuracy
Train	0.008	0.998
Test	0.097	0.982

나아가 Train Data와 Test Data를 대상으로 클래스별 성능지표를 도출하여 학습 결과를 분석하고자 한다. 우선, Train Data를 대상으로 Confusion matrix를 계산하여 클래스별 분류 결과를 확인해보았다. 그림 3은 4개 클래스에 대한 Confusion matrix이며 x축은 학습 결과, y축은 실제 클래스를 의미한다. 이를 분석한 결과, blackice와 snow는 상호간 혼동이 일어나며, 실제 wet 이미지를 모델이 road로 혼동하는 결과가 나타났다. 이는 GRAYSCALE 변환으로 인해 빛의 특성이 손실되어 나타나는 결과라고 판단된다.

다음으로, Test Data를 대상으로 각 클래스의 accuracy, precision, recall를 비교한 결과, 블랙 아이스, 젖은 도로, 눈 쌓인 도로의 accuracy가 상대적으로 낮게 측정되었다. 이는 앞서 분석한 Confusion matrix와 동일하게 빛의 특성이 손실되어 나타나는 결과로 사료된다. 그러나 accuracy, precision, recall의 평균값은 0.982, 0.983, 0.983을 기록하여 유의미한 학습 결과를 도출한 것으로 판단된다.(표 4 참조)

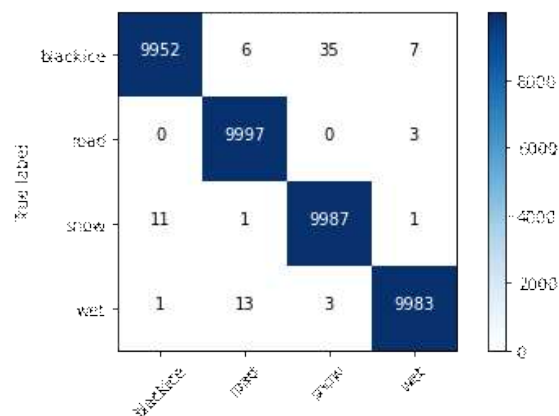


그림 3 Confusion Matrix

표 4 클래스별 accuracy, precision, recall

Class	accuracy	precision	recall
blackice	0.961	0.98	0.96
road	0.996	0.99	1.00
snow	0.981	0.97	0.98
wet	0.989	0.99	0.99
average	0.982	0.983	0.983

V. 결론

본 연구는 자율주행자동차의 블랙 아이스 사고 예방을 위해 CNN을 활용하여 육안으로 판단하기 어려운 블랙 아이스를 검출하는 연구를 수행하였다. 총 4개의 클래스로 분류하여 데이터를 구축하였으며, 전처리를 통해 각 클래스의 Train, Validation, Test Data를 구축하였다. 모델 학습 결과, 블랙 아이스의 정확도는 상대적으로 낮게 도출되었으나 전체적으로 유의미한 학습 결과를 도출하였다.

본 연구에서는 컴퓨팅 한계로 인해 GRAYSCALE을 통한 신경망 설계 및 학습을 진행하였으며, 이때 빛의 특성 소실에 의해 특정 클래스를 혼동하는 것으로 나타났다. 이는 향후 다수의 RGB 이미지를 활용하고, 더 깊은 신경망을 구현할 경우 모델의 개선도가 보다 높아질 것으로 판단된다.

본 연구는 도로의 잠재적인 위험을 검출하는 연구로 자율주행자동차의 사고를 예방하는 것에 의의가 있다. 또한, 이미지 인식 및 분류에 있어 카메라, 드론 등 타 산업과 연계 가능성이 높으므로 향후 융합 연구의 기초자료로 활용할 수 있을 것으로 기대된다.

참고문헌

- 통계청(2017), “2017년 하반기 연구보고서”, p.227.
- 자율주행차 융·복합 미래포럼(2018), “2018년 자율주행차 융·복합 미래포럼 운영용역 최종보고서”, p.50.
- Choubisa, T., Kashyap, M., & Chaitanya, K. K. (2018, September). Human Crawl vs Animal Movement and Person with Object Classifications Using CNN for Side-view Images from Camera. In 2018 International Conference on Advances in Computing, Communications and Informatics (ICACCI) (pp. 48-54). IEEE.
- Qian, R., Liu, Q., Yue, Y., Coenen, F., & Zhang, B. (2016, August). Road surface traffic sign detection with hybrid region proposal and fast R-CNN. In 2016 12th International Conference on Natural Computation, Fuzzy Systems and Knowledge Discovery (ICNC-FSKD) (pp. 555-559). IEEE.
- 실동현, 오지훈, & 김홍진. (2020). 콘크리트 균열 탐지를 위한 딥 러닝 기반 CNN 모델 비교. 대한건축학회 논문집-구조계, 36(3), 113-120.
- 양동욱, & 서승우. (2017). Convolutional Neural Network 을 사용한 실시간 교통표지판 인식 기술. 대한전자공학 학회 학술대회, 971-972.
- 이민혜, 남광우, & 이창우. (2019). Mask R-CNN 을 이용한 항공 영상에서의 도로 균열 검출. 한국산업정보학회논문지, 24(3), 23-29.